Clasificación de la evaluación de la docencia por parte de los estudiantes

Ana Gabriela Argüello Cedeño, Juan David Bernal Maldonado, Jean Karlo Buitrago Orozco, Kevin Yavari Yoshioka, Rui Yu Lei Wu

Abstract

Uno de los principales desafíos en el análisis de las evaluaciones del desempeño docente es el volumen de comentarios y opiniones abiertas proporcionadas por los estudiantes, cuya revisión y clasificación puede resultar un proceso complejo y demandante. Ante esta problemática, se propone el desarrollo de un sistema de clasificación automática de opiniones estudiantiles mediante técnicas de aprendizaje automático (Machine Learning), orientado a identificar la polaridad de los comentarios en tres categorías: positiva, negativa y neutral. El objetivo principal es facilitar el análisis de la retroalimentación estudiantil mediante el procesamiento e interpretación de datos textuales, permitiendo identificar tendencias en las percepciones de los estudiantes y proporcionar información organizada y oportuna que contribuya a los procesos de evaluación y mejoramiento continuo de la práctica docente.

Keywords

Clasificación de evaluación, TF-IDF, regresión logística, Embeddings semánticos, Linear SVM

Introducción

La evaluación docente realizada por los estudiantes (Student Evaluation of Teaching, SET) es una práctica común en la educación superior. Sin embargo, su utilidad y validez siguen siendo objeto de debate, ya que no es suficiente por sí sola para evaluar la calidad de la enseñanza [1]. Estas evaluaciones incluyen comentarios abiertos que permiten conocer las opiniones de los estudiantes y complementan las calificaciones numéricas. No obstante, revisar y clasificar manualmente estos comentarios requiere mucho tiempo, especialmente cuando existe una gran cantidad de información, lo que puede retrasar la entrega de retroalimentación a los docentes.

Para abordar este problema, el análisis de sentimientos se ha utilizado en diferentes estudios del ámbito educativo. Una revisión de 92 investigaciones publicadas entre 2015 y 2020 muestra que estas técnicas han evolucionado desde métodos basados en diccionarios y algoritmos tradicionales de clasificación hacia modelos de aprendizaje profundo. Además, el estudio destaca la importancia de contar con datos bien organizados y métodos estandarizados para mejorar los resultados. También señala que algunas técnicas funcionan bien en determinados contextos, pero pueden presentar dificultades cuando se aplican a otros ámbitos [2].

La manera de representar el texto es clave. TF-IDF da más peso a los términos menos frecuentes, creando representaciones simples y fáciles de entender, pero no reconoce que frases diferentes puedan tener el mismo significado. Los embeddings de oraciones solucionan parte de esto, generando vectores donde frases similares están cerca y se comparan con la similitud coseno [4]. También hay métodos para adaptar estos modelos a otros idiomas [5]. En este trabajo se utiliza el modelo público paraphrase-multilingual-MiniLM-L12-v2, que representa cada texto en 384 dimensiones y soporta unos 50 idiomas [6].

Este proyecto construye y evalúa un clasificador de polaridad (negativo, neutral y positivo) para 614 comentarios de estudiantes, en español, de siete cursos universitarios. Se comparan tres representaciones (TF-IDF, embeddings y su combinación) con cinco clasificadores y una línea base, implementados con scikit-learn [7]. La selección y el ajuste de hiperparámetros se hacen con validación cruzada estratificada y macro-F1, la evaluación final se realiza sobre un conjunto de prueba independiente y se analizan los errores del modelo, en particular los comentarios que mezclan elogio y crítica.

2. Materiales y métodos

La Figura 1 muestra el flujo de trabajo completo. Cada subsección corresponde a una etapa de ese flujo. Todo el proceso se implementó en Python con scikit-learn [7] y sentence-transformers. Se usó la semilla 42 en todos los procedimientos aleatorios para que los resultados se puedan reproducir.

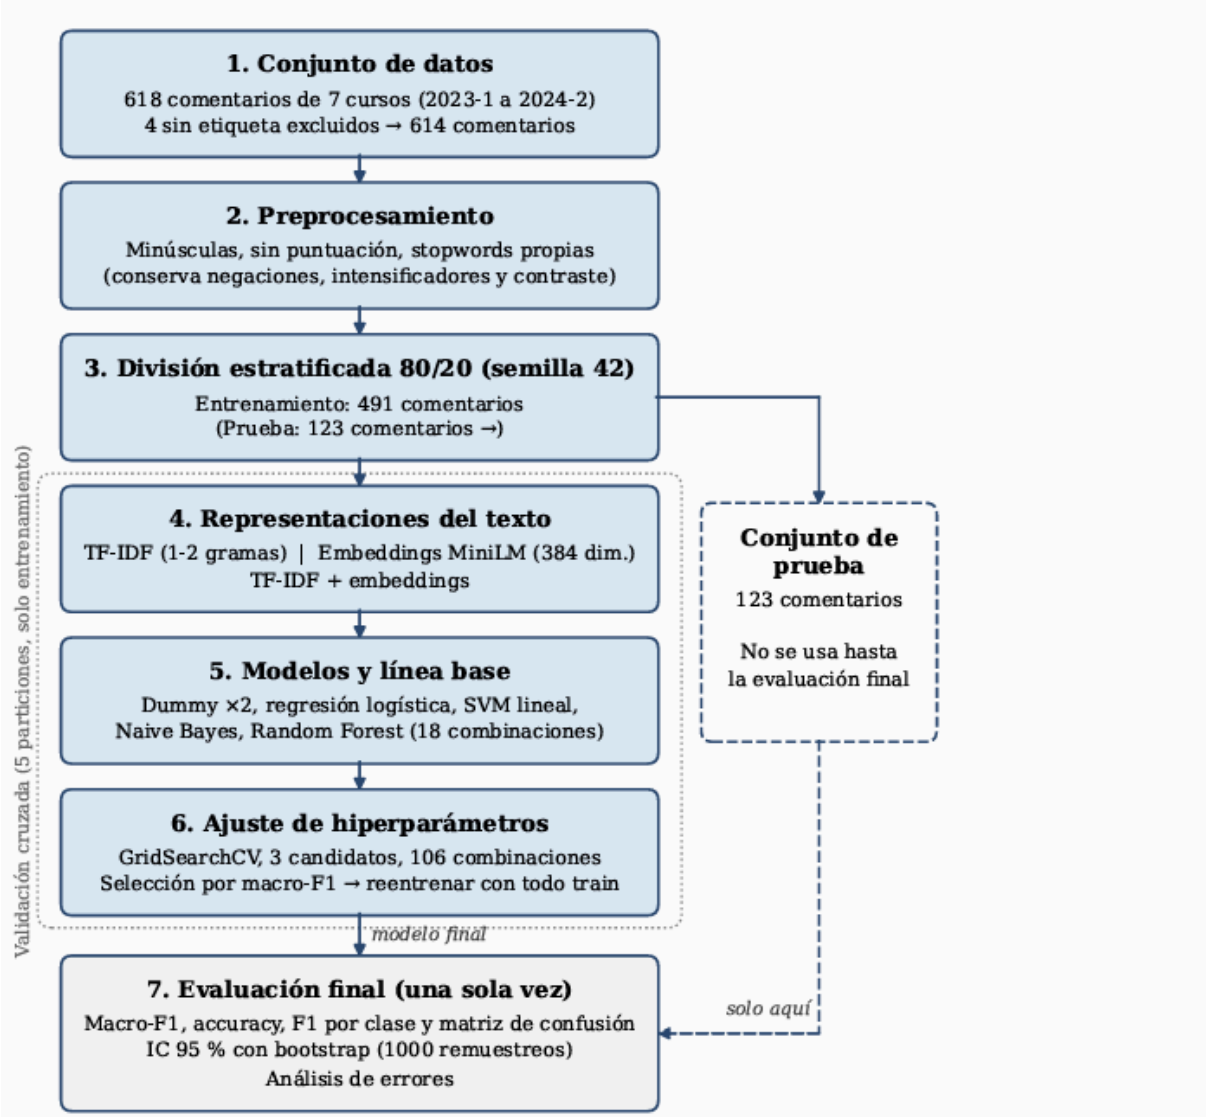


Figura 1. Flujo de trabajo del clasificador de polaridad. Los pasos 4 a 6 usan solo el conjunto de entrenamiento con validación cruzada; el conjunto de prueba se usa una única vez en la evaluación final.
Fuente: elaboración propia.

2.1 Conjunto de datos

La base de datos tiene 618 comentarios abiertos escritos en español por estudiantes en la evaluación docente de siete cursos de Ingeniería de Sistemas: Sistemas Operativos (145), Arquitectura del Computador (92), Programación Paralela (85), Sistemas Distribuidos (77), Sistemas Inteligentes (76),

Fundamentos de Programación (73) y Bases de Datos (70). Los comentarios abarcan los semestres 2023-1 a 2024-2 y provienen de tres archivos fuente. Cada comentario tiene una etiqueta de polaridad básica: negativo, neutral o positivo. Cuatro comentarios (id 32, 211, 243 y 461) no tenían etiqueta ni texto procesado, y se excluyeron. El conjunto final tiene 614 comentarios: 258 neutrales (42,0 %), 204 negativos (33,2 %) y 152 positivos (24,8 %). Los comentarios miden en promedio 45 palabras (mediana 43, mínimo 6, máximo 120).

2.2 Preprocesamiento

A partir del texto original se generó una versión normalizada (`texto_limpio`). El texto se pasó a minúsculas, se eliminaron los signos de puntuación y se quitaron las palabras vacías con una lista propia. Esa lista elimina artículos, preposiciones, pronombres y verbos auxiliares de alta frecuencia (por ejemplo, *de*, *el*, *la*, *que*, *es*, *fue*, *ha*). En cambio, conserva tres grupos de palabras que las listas estándar suelen descartar y que cambian la polaridad de un comentario:

- negaciones: *no*, *ni*, *nada*, *tampoco*, *sin*;
- intensificadores y cuantificadores: *muy*, *más*, *poco*, *bastante*, *demasiado*, *menos*, *tan*;
- conectores de contraste: *pero*, *aunque*, *sin embargo*.

Además, se creó una variable binaria (`contraste`). Esta variable marca los comentarios que contienen un conector adversativo (*pero*, *aunque*, *sin embargo*, *no obstante*), es decir, los que combinan elogio y crítica. El 76,2 % de los comentarios (468 de 614) tiene contraste. Esta variable no se usa como entrada de los modelos, solo en el análisis de errores. El texto normalizado alimenta las representaciones TF-IDF. Los embeddings se calculan sobre el texto original, porque los modelos de oraciones se entrenaron con frases completas y aprovechan los conectores y la puntuación.

2.3 División de los datos

Los 614 comentarios se dividieron en un conjunto de entrenamiento (80 %, 491 comentarios) y uno de prueba (20 %, 123 comentarios). La división fue estratificada por polaridad, con semilla 42. Se verificó que ningún identificador ni texto aparezca en ambos conjuntos. El conjunto de prueba no se usó en ninguna decisión de diseño. Solo interviene en la evaluación final (Sección 2.7). La Tabla 1 muestra que la estratificación conserva las proporciones de clase.

Tabla 1. Distribución de clases por partición.

Clase	Entrenamiento	Prueba	Total
Neutral	206 (42,0 %)	52 (42,3 %)	258 (42,0 %)
Negativo	163 (33,2 %)	41 (33,3 %)	204 (33,2 %)
Positivo	122 (24,8 %)	30 (24,4 %)	152 (24,8 %)
Total	**491**	**123**	**614**

Fuente: elaboración propia.

2.4 Representaciones del texto

Se compararon tres representaciones:

1. **TF-IDF** [3]. La versión principal usa unigramas y bigramas de palabras (`ngram_range=(1,2)`), descarta los términos que aparecen en menos de dos documentos (`min_df=2`) y aplica escalado logarítmico de la frecuencia (`sublinear_tf=True`). Así captura expresiones como *no explicaba* o *muy clara*. En la comparación inicial también se evaluó TF-IDF de n-gramas de caracteres (3 a 5, `char_wb`), que tolera mejor los errores de escritura y las variaciones de una misma palabra.
2. **Embeddings semánticos**. Cada comentario se codificó con el modelo preentrenado `paraphrase-multilingual-MiniLM-L12-v2` [4]–[6] en un vector de 384 dimensiones, normalizado a norma 1. Como el modelo no se ajusta con nuestros datos, los embeddings se calcularon una sola vez para el conjunto de entrenamiento.
3. **TF-IDF + embeddings**. Los dos vectores se concatenaron con un `ColumnTransformer`. Como ambos tienen norma 1, ninguno domina al otro por escala.

El vectorizador TF-IDF va siempre dentro de un `Pipeline`. De esta forma, en cada partición de la validación cruzada, el vocabulario y los pesos IDF se aprenden solo con los datos de entrenamiento de esa partición, y no hay fuga de información. Para aislar el efecto de la representación, las tres variantes se compararon con el mismo clasificador: regresión logística con `class_weight="balanced"`.

2.5 Modelos y línea base

Cada representación se combinó con cinco clasificadores, con sus hiperparámetros por defecto:

- **Línea base:** dos `DummyClassifier`, uno que siempre predice la clase mayoritaria y otro que predice al azar respetando la distribución de clases. Sirven como referencia mínima.
- **Regresión logística** (`max_iter=5000`).
- **SVM lineal** (`LinearSVC`, `max_iter=10000`).
- **Naive Bayes**: `ComplementNB` con TF-IDF, que está pensado para texto con clases desbalanceadas (`MultinomialNB` obtuvo un macro-F1 de 0,46 porque predecía casi siempre *neutral*). Con embeddings se usó `GaussianNB`, porque los embeddings tienen valores negativos. En la representación combinada se usó `ComplementNB`, con los embeddings escalados a [0, 1] mediante `MinMaxScaler`.
- **Random Forest** (300 árboles).

Para compensar la menor proporción de comentarios positivos, la regresión logística, la SVM lineal y Random Forest usan `class_weight="balanced"`. En total se evaluaron 18 combinaciones de modelo y representación.

2.6 Ajuste de hiperparámetros

A partir de los resultados del paso 5 se ajustaron los tres candidatos con mayor macro-F1 medio. Se usó `GridSearchCV` con validación cruzada estratificada de 5 particiones (`StratifiedKFold`, `shuffle=True`, semilla 42) y macro-F1 como criterio de selección. El espacio de búsqueda de la Tabla 2 suma 106 combinaciones. Además de la métrica de validación, se registró el macro-F1 en entrenamiento para detectar sobreajuste. El mejor candidato se reentrenó con todo el conjunto de entrenamiento (`refit=True`) y se guardó para la evaluación final.

Tabla 2. Espacio de búsqueda y mejores parámetros.

Tabla 2. Espacio de búsqueda de hiperparámetros y mejores parámetros.

Candidato	Hiperparámetros explorados	Combinaciones	Mejores parámetros
Regresión logística + TF-IDF + embeddings	C ∈ {0,1; 0,3; 1; 3; 10; 30; 100} n-gramas ∈ {(1,1), (1,2)} min_df ∈ {1, 2, 3}	42	C = 10 n-gramas (1,2) min_df = 2
SVM lineal + TF-IDF + embeddings	C ∈ {0,01; 0,03; 0,1; 0,3; 1; 3; 10; 30} n-gramas ∈ {(1,1), (1,2)} min_df ∈ {1, 2, 3}	48	C = 1 n-gramas (1,2) min_df = 2
SVM lineal + embeddings	C ∈ {0,01; 0,03; 0,1; 0,3; 1; 3; 10; 30} class_weight ∈ {balanced, None}	16	C = 1 class_weight = None
Total		**106**	

Fuente: elaboración propia.

2.7 Métricas de evaluación

La métrica principal es el **macro-F1**: el promedio no ponderado del F1 de las tres clases. Se eligió porque el corpus está desbalanceado. La accuracy puede ser alta solo por predecir bien la clase mayoritaria (el Dummy de clase mayoritaria obtiene 0,42 de accuracy con apenas 0,20 de macro-F1). También se reportan la accuracy, la precisión, el recall y el F1 por clase, y la matriz de confusión. En validación cruzada, cada resultado se da como media ± desviación estándar de las 5 particiones. Cuando la diferencia entre dos configuraciones es menor que esa desviación, no se interpreta como una mejora real.

El modelo final se evalúa una única vez sobre el conjunto de pruebas. Con solo 123 comentarios, una sola estimación puede variar bastante.

Por eso, el intervalo de confianza del 95 % de cada métrica se estimó con bootstrap de percentiles (1000 remuestreos con reemplazo de los 123 comentarios, semilla 42). Para comparar el modelo final con los otros candidatos y con las líneas base se usaron los mismos remuestreos en todos los modelos (bootstrap pareado), y una diferencia se considera no concluyente cuando su intervalo incluye el cero. Los otros dos candidatos del ajuste y las dos líneas base se reentrenaron con el conjunto de entrenamiento y sus mejores parámetros, y se evaluaron en prueba solo como referencia; su resultado no cambia la elección del modelo final. La relación entre el contraste y el error se evaluó con la prueba exacta de Fisher.

3. Resultados y discusión

Salvo en la Sección 3.4, todos los resultados provienen de validación cruzada estratificada de 5 particiones sobre el conjunto de entrenamiento (491 comentarios) y se reportan como media ± desviación estándar.

3.1 Comparación de representaciones

Con el mismo clasificador (regresión logística balanceada), los embeddings MiniLM obtuvieron el mayor macro-F1 medio (0,661 ± 0,035). Le siguen TF-IDF de palabras (0,635 ± 0,016) y TF-IDF de caracteres (0,621 ± 0,017). La diferencia entre embeddings y TF-IDF de palabras (0,026) es menor que la desviación de los embeddings, así que con estos datos no se puede afirmar que una representación supere a la otra.

Las dos representaciones fallan en comentarios distintos. De los 491 comentarios, 71 los clasifica bien solo el modelo con embeddings, 63 sólo el modelo con TF-IDF, 253 ambos y 104 ninguno. También se equivocan de forma diferente. TF-IDF reconoce bien la clase neutral (140 de 206 aciertos), pero confunde muchos positivos con neutrales (41 de 122). Los embeddings reconocen mejor las clases negativa (126 de 163) y positiva (89 de 122), pero pierden neutrales hacia las otras dos clases (51 hacia negativo y 46 hacia positivo). Estos errores complementarios fueron la razón para evaluar la combinación de ambas representaciones en el paso 5.

3.2 Línea base y comparación de modelos

La Tabla 3 muestra el macro-F1 de las 18 combinaciones de modelo y representación con hiperparámetros por defecto. La línea base de clase mayoritaria alcanza 0,420 de accuracy pero solo 0,197 de macro-F1, porque predice siempre *neutral*. La línea base aleatoria estratificada obtiene 0,301. Todos los clasificadores reales quedan entre 0,611 y 0,703, es decir, al menos 0,31 puntos por encima de la mejor línea base, una distancia muy superior a cualquier desviación observada.

Tabla 3. Macro-F1 (media ± desviación estándar, validación cruzada de 5 particiones) por modelo y representación, con hiperparámetros por defecto.

Modelo	TF-IDF	Embeddings	TF-IDF + embeddings
SVM lineal	0,611 ± 0,048	0,694 ± 0,034	0,703 ± 0,040
Regresión logística	0,635 ± 0,016	0,661 ± 0,035	0,692 ± 0,041
Random Forest	0,622 ± 0,020	0,667 ± 0,033	0,674 ± 0,024
Naive Bayes	0,627 ± 0,041	0,646 ± 0,049	0,664 ± 0,019
Dummy (aleatorio estratificado)	0,301 ± 0,051	0,301 ± 0,051	0,301 ± 0,051
Dummy (clase mayoritaria)	0,197 ± 0,001	0,197 ± 0,001	0,197 ± 0,001

Fuente: elaboración propia.

La representación combinada obtuvo el mayor macro-F1 medio con los cuatro clasificadores. En regresión logística, el macro-F1 pasa de 0,635 (TF-IDF) a 0,661 (embeddings) y a 0,692

(combinación). La mejora de 0,057 sobre TF-IDF supera la desviación estándar. Los tres mejores resultados fueron SVM lineal con la combinación (0,703 ± 0,040), SVM lineal con embeddings (0,694 ± 0,034) y regresión logística con la combinación (0,692 ± 0,041). Sus diferencias son menores que la desviación, así que se consideran equivalentes y los tres pasaron al ajuste de hiperparámetros.

El macro-F1 en entrenamiento muestra que varios modelos memorizan los datos. Random Forest (con las tres representaciones) y SVM lineal con TF-IDF o con la combinación alcanzan 1,0, mientras su macro-F1 en validación está entre 0,61 y 0,70. Con embeddings solos, la distancia es mucho menor: SVM lineal obtiene 0,823 en entrenamiento frente a 0,694 en validación.

3.3 Ajuste de hiperparámetros

De los tres candidatos ajustados (Tabla 2), la regresión logística con TF-IDF + embeddings (C = 10, unigramas y bigramas, min_df = 2) obtuvo el mayor macro-F1 medio: 0,714 ± 0,042. Le siguen la SVM lineal con la combinación (0,703 ± 0,040) y la SVM lineal con embeddings (0,700 ± 0,030). El ajuste subió la regresión logística de 0,692 a 0,714. Esa ganancia (0,022) es menor que la desviación, así que no es una mejora concluyente.

El resultado tampoco depende de un valor exacto de los hiperparámetros. Tomando como umbral la mejor media menos una desviación (0,714 − 0,042 ≈ 0,673), 74 de las 106 combinaciones probadas están dentro de ese rango: 32 de 42 en regresión logística, 35 de 48 en SVM con la combinación y 7 de 16 en SVM con embeddings. Las cinco mejores combinaciones de cada candidato difieren en menos de 0,015. Solo los valores muy bajos de C en la SVM con embeddings rinden claramente peor (mínimo 0,531). En consecuencia, el modelo final es el de mayor macro-F1 medio, pero no está demostrado que sea mejor que los otros dos.

El sobreajuste se mantiene. El modelo elegido tiene macro-F1 de 1,0 en entrenamiento, igual que la SVM con la combinación. La SVM con embeddings, en cambio, tiene una brecha mucho menor (0,825 frente a 0,700). Con un rendimiento en validación equivalente, sería una alternativa más simple y que probablemente generaliza mejor.

En validación cruzada, el modelo final logra un F1 de 0,751 en la clase negativa, 0,699 en la neutral y 0,694 en la positiva, con accuracy de 0,715.

3.4 Evaluación en el conjunto de prueba

El modelo final, reentrenado con los 491 comentarios de entrenamiento, se evaluó una sola vez sobre los 123 comentarios de prueba (Tabla 4, Figura 2). Obtuvo un macro-F1 de 0,664 (IC 95 %: 0,571–0,748) y una accuracy de 0,667 (IC 95 %: 0,585–0,748). Ambos valores quedan muy por encima de las líneas base evaluadas en el mismo conjunto de prueba (macro-F1 de 0,198 para la clase mayoritaria y 0,338 para la aleatoria estratificada); en los dos casos, el intervalo de la diferencia pareada excluye el cero (0,368–0,558 y 0,190–0,450). Esto confirma que el modelo aprendió patrones útiles para predecir la polaridad.

El macro-F1 en prueba es 0,050 menor que el estimado en validación cruzada (0,714 ± 0,042). La diferencia es apenas mayor que una desviación estándar, y el valor de validación cruzada cae dentro del intervalo de confianza de prueba. Con 123 comentarios no se puede asegurar que la caída sea

real y no producto del azar en la partición. Aun así, va en la dirección que anticipaba el sobreajuste de la Sección 3.3 (macro-F1 de 1,0 en entrenamiento). Lo prudente es tomar el valor de prueba como la estimación del rendimiento con datos nuevos.

Como referencia, los otros dos candidatos del ajuste obtuvieron en prueba un macro-F1 de 0,664 (IC 95 %: 0,576–0,747), la SVM lineal con TF-IDF + embeddings, y de 0,691 (IC 95 %: 0,607–0,769), la SVM lineal con embeddings. Las diferencias pareadas con el modelo final no son concluyentes (de −0,029 a 0,033 y de −0,094 a 0,041, respectivamente), lo que coincide con la equivalencia observada en validación cruzada (Sección 3.3). La SVM con embeddings es la que menos cae respecto de su valor de validación cruzada (0,700 frente a 0,691), lo que es coherente con su menor sobreajuste. Por el protocolo fijado, este resultado no cambia la elección del modelo final.

Tabla 4. Resultados del modelo final en el conjunto de prueba (n = 123).
Entre corchetes, intervalo de confianza del 95 % (bootstrap, 1000 remuestreos).

Clase	**Precisión**	**Recall**	**F1**	**Soporte**
Negativo	0,744	0,780	0,762	41
Neutral	0,627	0,615	0,621	52
Positivo	0,621	0,600	0,610	30
Macro promedio	0,664	0,665	0,664 [0,571 – 0,748]	123
Accuracy			0,667 [0,585 – 0,748]	123

Fuente: elaboración propia.

Por clase, la negativa obtiene el F1 más alto (0,762). Las clases neutral (0,621) y positiva (0,610) quedan muy por debajo. La Figura 2 muestra el origen de esa diferencia. El 40,0 % de los comentarios positivos (12 de 30) se clasificó como neutral. De los neutrales, el 21,2 % se clasificó como negativo y el 17,3 % como positivo. Las confusiones directas entre polos opuestos son casi nulas: 2 negativos se predijeron como positivos y ningún positivo se predijo como negativo.

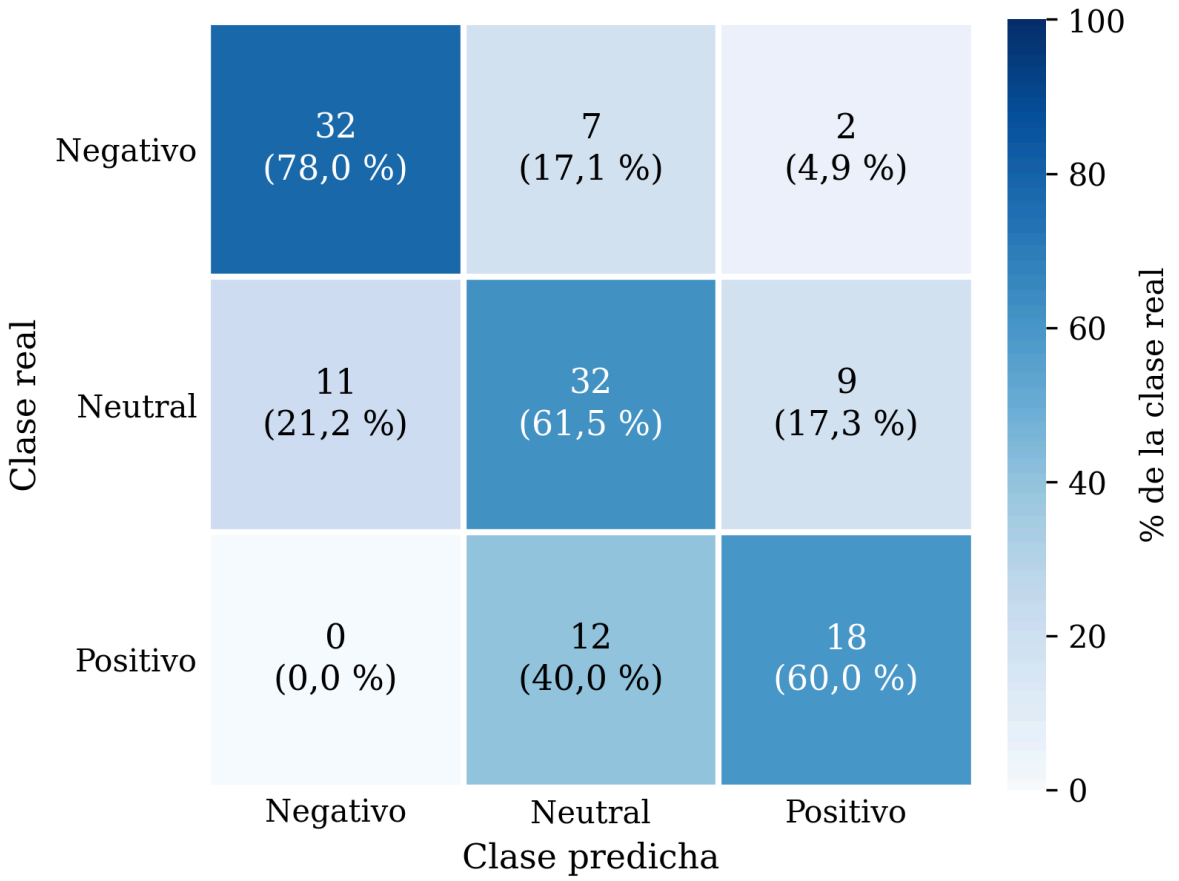


Figura 2. Matriz de confusión del modelo final en el conjunto de prueba (n = 123). Cada celda muestra el número de comentarios y, entre paréntesis, el porcentaje de su clase real. Fuente: elaboración propia.

3.5 Análisis de errores

Comentarios con contraste. Los comentarios que mezclan elogio y crítica son los más difíciles para todas las configuraciones. En validación cruzada, el modelo final acierta el 80,3 % de los comentarios sin contraste y el 68,7 % de los que tienen contraste. En el paso 4 la caída fue parecida: de 73,5 % a 61,5 % con TF-IDF y de 79,5 % a 61,8 % con embeddings. Entre los 104 comentarios en que fallan ambas representaciones, el 82,7 % tiene contraste, una proporción mayor que el 76,2 % del conjunto de entrenamiento. Por ejemplo, el comentario 22 (*"El contenido fue excelente, pero la retroalimentación de los exámenes me dejó algo confundido"*) tiene la etiqueta *negativo* y ambos modelos lo clasificaron como *neutral*. En comentarios como este, la etiqueta depende de cuánto peso se le da a cada parte de la frase, y eso no se deduce de las palabras por sí solas.

En el conjunto de prueba la brecha es mayor: el modelo acierta el 86,2 % de los comentarios sin contraste (25 de 29) y el 60,6 % de los que lo tienen (57 de 94), es decir, una tasa de error de 13,8 % frente a 39,4 % (prueba exacta de Fisher, p = 0,013). La variable contraste no detecta la locución *a pesar de*: 10 comentarios de prueba que la contienen quedaron marcados sin contraste, y dos de los cuatro errores sin contraste (420 y 510) son de ese tipo, por lo que la brecha real podría ser algo mayor.

La clase neutral. En la matriz de confusión de validación cruzada del modelo final, 125 de los 140 errores (89 %) tienen la clase neutral como etiqueta real o como predicción. En prueba la proporción es aún mayor: 39 de los 41 errores (95 %). Las confusiones directas entre negativo y positivo son pocas: 15 en validación cruzada y 2 en prueba. El modelo casi siempre identifica el sentido general del comentario. Lo que le cuesta es decidir cuándo un comentario mixto deja de ser neutral, y es la misma frontera que hace difícil etiquetar los comentarios con contraste. En prueba, esta dificultad se nota sobre todo en la clase positiva, donde 4 de cada 10 comentarios se clasificaron como neutrales.

Etiquetas discutibles. Algunos errores se explican mejor por la etiqueta que por el modelo:

- El comentario 65 (*"El curso fue bastante interesante y dinámico… El profesor es muy atento y dispuesto a ayudar"*) está etiquetado como *negativo*, aunque no tiene ninguna crítica.
- El comentario 190 (*"El curso fue un desafío pero motivador. Los contenidos fueron muy interesantes"*) también está etiquetado como *negativo*.
- El comentario 603 no es una evaluación de un curso. Es un mensaje dirigido a un "estimado estudiante" que termina con la plantilla "[Tu nombre]", y además está etiquetado como *negativo*.

En los tres casos, ambos modelos predijeron *positivo*. Estas etiquetas añaden ruido al entrenamiento y a la evaluación, y fijan un límite al rendimiento que se puede alcanzar.

Causas de los errores en prueba. Se revisaron manualmente los 41 comentarios de prueba mal clasificados y se asignó a cada uno una sola causa probable, con este orden de prioridad: comentario fuera de contexto o de baja calidad, etiqueta discutible (la predicción del modelo parece razonable), negación que invierte la polaridad, contraste y otra. Un comentario mixto etiquetado como neutral se consideró bien etiquetado. La Tabla 5 resume el resultado. El contraste explica 22 errores: en la mayoría, el modelo sigue solo una de las partes del comentario, como en el 148, donde una crítica inicial seguida de un elogio introducido por *sin embargo* se clasificó como negativo. Le siguen las etiquetas discutibles (14), como el comentario 276, etiquetado como neutral aunque solo expresa decepción. Las negaciones explican 3 errores; en el comentario 82, completamente positivo, la expresión *sin problemas* probablemente contribuye a que se prediga neutral. Los 2 comentarios de baja calidad provienen del tercer archivo fuente; uno de ellos (601) se contradice a sí mismo (*"La experiencia fue sencilla pero notoriamente complicada"*). Once asignaciones son dudosas y admiten una segunda causa, casi siempre contraste o etiqueta discutible. Además, en dos comentarios etiquetados como positivos (318 y 278) el texto afirma que la emoción del estudiante fue neutral, lo que sugiere que la etiqueta de polaridad y la redacción no siempre describen lo mismo.

Tabla 5. Causas probables de los 41 errores del modelo final en el conjunto de prueba.

Causa	**Errores**	**Con contraste**	**Dudosos**
Fuera de contexto o baja calidad	2	2	0
Etiqueta discutible	14	11	5
Negación que invierte la polaridad	3	2	2

Contraste	22	22	4
Otra	0	0	0
Total	**41**	**37**	**11**

Fuente: elaboración propia.

3.6 Limitaciones

- **Falta una columna de autor.** No hay forma de saber qué estudiante escribió cada comentario, así que la división no pudo agruparse por autor. Comentarios del mismo estudiante pueden haber quedado en entrenamiento y en prueba, y el modelo podría aprovechar su estilo de escritura. Si eso ocurrió, el rendimiento en prueba estaría sobreestimado.
- **Conjunto de prueba pequeño.** Con 123 comentarios (30 positivos), cada error cambia la métrica de forma apreciable. El intervalo de confianza del macro-F1 en prueba mide casi 0,18 puntos (0,571–0,748), y dentro de ese rango caben todas las configuraciones que resultaron equivalentes en el ajuste.
- **Embeddings no especializados.** `paraphrase-multilingual-MiniLM-L12-v2` se entrenó para detectar paráfrasis, no para analizar sentimiento [6]. Dos frases con el mismo tema y polaridad opuesta pueden quedar cerca en su espacio vectorial, y eso afecta sobre todo a los comentarios con contraste.
- **Sobreajuste.** El modelo final alcanza macro-F1 de 1,0 en entrenamiento, con una dimensión (vocabulario TF-IDF más 384 componentes) muy superior al número de ejemplos. En prueba obtuvo 0,664, por debajo del 0,714 de validación cruzada, una caída coherente con ese sobreajuste. La SVM lineal con solo embeddings, que tenía una brecha mucho menor entre entrenamiento y validación, obtuvo en prueba un macro-F1 de 0,691, sin diferencia concluyente con el modelo final. Se evaluó solo como referencia: adoptarla después de ver el conjunto de prueba invalidaría la evaluación, por lo que queda como la alternativa natural para trabajos futuros.
- **Calidad de las etiquetas.** Hay comentarios mal etiquetados o que no son evaluaciones (Sección 3.5). El 76,2 % de los comentarios tiene contraste, lo que vuelve ambigua la frontera entre neutral y las otras dos clases.
- **Selección posiblemente optimista.** La comparación de modelos (Sección 3.2) y el ajuste de hiperparámetros (Sección 3.3) usaron las mismas particiones de validación cruzada, sin validación cruzada anidada. Elegir la mejor de 106 combinaciones con esas mismas particiones tiende a sobrestimar su rendimiento, lo que también ayuda a explicar que el macro-F1 en prueba sea menor que el de validación.

4. Conclusiones

Este trabajo construyó y evaluó un clasificador de polaridad para 614 comentarios abiertos de evaluación docente, escritos en español por estudiantes de siete cursos de Ingeniería de Sistemas, con el fin de facilitar el análisis de esa retroalimentación. El modelo final, una regresión logística sobre la combinación de TF-IDF y embeddings paraphrase-multilingual-MiniLM-L12-v2, obtuvo en un conjunto de prueba independiente de 123 comentarios un macro-F1 de 0,664 (IC 95 %: 0,571–0,748) y una accuracy de 0,667, muy por encima de las líneas base de clase mayoritaria (0,198) y aleatoria estratificada (0,338). Con este desempeño, el modelo sirve para ordenar y resumir grandes volúmenes de comentarios, pero uno de cada tres queda mal clasificado, por lo que no reemplaza la lectura humana de los casos individuales.

La representación del texto tuvo más efecto que la elección del clasificador. Con el mismo clasificador, los embeddings (0,661) y TF-IDF de palabras (0,635) no se diferenciaron de forma concluyente, pero se equivocaron en comentarios distintos: TF-IDF reconoció mejor la clase neutral y los embeddings, las clases negativa y positiva. Al combinarlas, el macro-F1 de la regresión logística subió a 0,692, una mejora sobre TF-IDF mayor que la desviación entre particiones, y la combinación fue la mejor representación con los cuatro clasificadores. En cambio, el ajuste de hiperparámetros llevó el modelo a 0,714 ± 0,042 en validación cruzada con una ganancia menor que la desviación, 74 de las 106 combinaciones probadas quedaron a menos de una desviación de la mejor, y los tres candidatos finales resultaron equivalentes tanto en validación cruzada como en prueba (0,664, 0,664 y 0,691).

El modelo final memoriza el entrenamiento (macro-F1 de 1,0) y en prueba rindió 0,050 menos que en validación cruzada, aunque este valor cae dentro del intervalo de confianza de prueba. La SVM lineal con solo embeddings tiene una brecha mucho menor entre entrenamiento y validación (0,825 frente a 0,700) y obtuvo 0,691 en prueba, por lo que es la alternativa más simple para trabajos futuros.

La principal dificultad está en la frontera entre la clase neutral y las clases polares, no en distinguir lo positivo de lo negativo. En prueba, la clase neutral participa en 39 de los 41 errores, solo dos errores confunden negativo con positivo y el 40,0 % de los comentarios positivos se clasificó como neutral. Esa frontera coincide con los comentarios que mezclan elogio y crítica, que son el 76,2 % del corpus: su tasa de error en prueba fue de 39,4 %, frente a 13,8 % en los comentarios sin contraste ($p = 0,013$). El análisis manual atribuyó 22 de los 41 errores al contraste y 14 a etiquetas discutibles, y encontró comentarios que no son evaluaciones reales. Parte del error, por tanto, proviene de la anotación y no del modelo.

Estos resultados deben leerse con cautela: no fue posible agrupar la partición por autor, el conjunto de prueba es pequeño, el modelo de embeddings no fue entrenado para análisis de sentimiento y la selección del modelo pudo ser optimista al usar las mismas particiones de validación. Como trabajo futuro se propone revisar el etiquetado de los comentarios mixtos con criterios explícitos, contar con un identificador anónimo de autor para particionar por estudiante, evaluar modelos con menos sobreajuste, como la SVM con embeddings, y probar representaciones entrenadas para sentimiento que tengan en cuenta por separado cada parte de un comentario con contraste.

Referencias

1. P. Spooren, B. Brockx, and D. Mortelmans, “On the validity of student evaluation of teaching: The state of the art,” *Rev. Educ. Res.*, vol. 83, no. 4, pp. 598–642, Dec. 2013, doi: 10.3102/0034654313496870.
   Enlace: https://doi.org/10.3102/0034654313496870
2. Z. Kastrati, F. Dalipi, A. S. Imran, K. Pireva Nuci, and M. A. Wani, “Sentiment analysis of students’ feedback with NLP and deep learning: A systematic mapping study,” *Appl. Sci.*, vol. 11, no. 9, Art. no. 3986, Apr. 2021, doi: 10.3390/app11093986.
   Enlace (acceso abierto): https://www.mdpi.com/2076-3417/11/9/3986
3. K. Spärck Jones, “A statistical interpretation of term specificity and its application in retrieval,” *J. Doc.*, vol. 28, no. 1, pp. 11–21, 1972, doi: 10.1108/eb026526.
   Enlace: https://doi.org/10.1108/eb026526
4. N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using Siamese BERT-networks,” in *Proc. 2019 Conf. Empirical Methods Natural Lang. Process. and 9th Int. Joint Conf. Natural Lang. Process. (EMNLP-IJCNLP)*, Hong Kong, China, 2019, pp. 3982–3992, doi: 10.18653/v1/D19-1410.
   Enlaces: https://aclanthology.org/D19-1410 y https://arxiv.org/abs/1908.10084
5. N. Reimers and I. Gurevych, “Making monolingual sentence embeddings multilingual using knowledge distillation,” in *Proc. 2020 Conf. Empirical Methods Natural Lang. Process. (EMNLP)*, 2020, pp. 4512–4525.
   Enlace: https://arxiv.org/abs/2004.09813
6. “paraphrase-multilingual-MiniLM-L12-v2,” Hugging Face. [Online]. Available: https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2. Accessed on: Nov. 8, 2026.
7. F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: https://jmlr.org/papers/v12/pedregosa11a.html